

Modelagem Preditiva do Coeficiente Assintótico Linear em Sistemas RIS sob Desvanecimento Nakagami- m Correlacionado via XGBoost

Bryan Fernando Sarango Rodríguez

Abstract—Este projeto investiga o uso de aprendizado de máquina para estimar o coeficiente assintótico linear associado ao regime de alta SNR de sistemas com superfícies inteligentes reconfiguráveis (RIS) sob desvanecimento Nakagami- m correlacionado. A obtenção analítica desse coeficiente depende da avaliação de uma série multidimensional de elevada complexidade, o que pode tornar custosas as análises envolvendo numerosas configurações do sistema. Propõe-se utilizar *Extreme Gradient Boosting* (XGBoost) como modelo substituto para aprender a relação entre os parâmetros estatísticos do canal e o coeficiente assintótico. A ampla faixa dinâmica da variável de interesse será tratada por uma transformação logarítmica durante o treinamento. A interpretabilidade do modelo será analisada por meio de SHAP (*SHapley Additive exPlanations*), com o objetivo de identificar a contribuição dos parâmetros de entrada e de suas interações, especialmente da correlação espacial e do número de elementos RIS. O desempenho será avaliado em termos de precisão preditiva, capacidade de generalização e ganho computacional, além da comparação do comportamento assintótico reconstruído com o modelo analítico e com simulações de Monte Carlo.

Index Terms—RIS, Nakagami- m , correlação espacial, coeficiente assintótico, XGBoost, SHAP, regressão tabular.

I. INTRODUÇÃO

Superfícies inteligentes reconfiguráveis (*Reconfigurable Intelligent Surfaces* – RIS) vêm sendo amplamente investigadas como uma tecnologia habilitadora para sistemas de comunicação sem fio de próxima geração, devido à possibilidade de controlar de forma programável o ambiente de propagação [1], [2]. Entretanto, a análise de desempenho desses sistemas torna-se significativamente mais desafiadora quando são considerados modelos de canal com desvanecimento Nakagami- m e correlação espacial entre os elementos da superfície. Em particular, o estudo apresentado em [3] demonstra que a correlação pode modificar de maneira relevante o comportamento assintótico da distribuição da razão sinal-ruído, afetando diretamente o coeficiente assintótico linear utilizado para caracterizar o desempenho no regime de alta SNR.

Esse coeficiente sintetiza o efeito conjunto de diferentes parâmetros físicos do sistema, incluindo o número de elementos da RIS, os parâmetros de desvanecimento, as potências médias dos canais e a estrutura de correlação espacial. Sua obtenção analítica, entretanto, depende da avaliação de uma expressão de elevada complexidade, envolvendo funções especiais e uma série multidimensional. Embora essa formulação permita uma caracterização rigorosa do sistema, o cálculo

repetido do coeficiente para diferentes combinações do número de elementos RIS, dos parâmetros de desvanecimento, das potências dos canais e dos níveis de correlação pode demandar elevado custo computacional.

Nesse contexto, técnicas de aprendizado de máquina podem ser utilizadas para construir modelos substitutos capazes de aproximar relações analíticas complexas com menor custo computacional. O presente trabalho propõe o emprego do *Extreme Gradient Boosting* (XGBoost) para estimar o coeficiente assintótico linear diretamente a partir dos parâmetros estatísticos do canal. O objetivo principal é avaliar se o XGBoost pode reproduzir com precisão os resultados fornecidos pelo modelo analítico e, simultaneamente, reduzir o custo computacional necessário para a avaliação de diferentes configurações do sistema. Adicionalmente, pretende-se investigar se o modelo aprendido preserva as principais tendências físicas associadas ao efeito da correlação espacial, do desvanecimento e do número de elementos da RIS.

A escolha do XGBoost está relacionada às características do problema considerado. O conjunto de dados possui natureza tabular, sendo cada amostra formada por parâmetros físicos do sistema e pelo correspondente valor do coeficiente obtido a partir do modelo analítico. O XGBoost utiliza *gradient boosting* de árvores de decisão, construindo iterativamente novos regressores para corrigir os erros produzidos pelas árvores anteriores e incorporando mecanismos de regularização para controlar a complexidade do modelo [4]. Essa estrutura permite representar relações não lineares e interações entre atributos sem exigir a definição prévia de uma forma funcional para o mapeamento entre entradas e saída. Além disso, métodos baseados em árvores permanecem altamente competitivos em tarefas de regressão com dados tabulares, como no presente problema, em que cada amostra é caracterizada por um conjunto de parâmetros físicos do sistema e pelo correspondente coeficiente assintótico.

Embora o XGBoost apresente elevada capacidade para modelar relações não lineares, sua estrutura de ensemble dificulta a interpretação direta das previsões. Por esse motivo, será utilizada a metodologia SHAP (*SHapley Additive exPlanations*) [5]. Essa abordagem permite quantificar a contribuição das diferentes variáveis de entrada para as previsões produzidas pelo modelo, possibilitando identificar quais parâmetros apresentam maior influência e como essa influência varia entre diferentes configurações do sistema. No contexto deste trabalho, a análise será particularmente direcionada ao efeito da correlação espacial e à sua interação com o número de

elementos da RIS, bem como à influência dos parâmetros de desvanecimento e das potências médias dos canais.

Dessa forma, a proposta combina três perspectivas complementares: a formulação analítica fornece os valores de referência para a geração dos dados, o XGBoost atua como modelo substituto para a estimativa eficiente do coeficiente assintótico, e SHAP fornece uma camada adicional de interpretabilidade para investigar o comportamento aprendido pelo modelo. A hipótese central é que essa abordagem seja capaz de fornecer estimativas suficientemente precisas para reproduzir o comportamento assintótico do sistema, com custo computacional inferior ao cálculo analítico repetitivo, ao mesmo tempo em que permite identificar relações relevantes entre os parâmetros físicos e o coeficiente de interesse. A validade dessa hipótese será analisada por meio de métricas de regressão, testes de generalização, comparação de custo computacional e validação do comportamento assintótico utilizando o modelo analítico e simulações de Monte Carlo.

II. DESCRIÇÃO DO PROBLEMA

Considera-se um sistema RIS com N elementos no qual a SNR recebida depende do somatório de produtos de variáveis aleatórias Nakagami- m correlacionadas, conforme:

$$S = \sum_{n=1}^N H_{1,n} H_{2,n} \quad (1)$$

onde $H_{1,n}$ e $H_{2,n}$, $n \in \{1, \dots, N\}$, representam os ganhos de canal nos enlaces transmissor-RIS e RIS-receptor, respectivamente. A análise assintótica da distribuição de S mostra que, para $s \rightarrow 0$, a função densidade de probabilidade (PDF) é dada por

$$f_S(s) \approx a_0 s^{b_0} \quad (2)$$

em que a_0 e b_0 representam os coeficientes linear e angular, respectivamente, e são dados por [3, eq. (10)]

$$a_0 = \frac{\Phi \Gamma(2m_<)^N}{\Gamma(2Nm_<)} \sum_{i_1, \dots, i_N=0}^{\infty} \frac{\Gamma(m_> + \sum_{l=1}^N i_l)}{\left(2 + \sum_{l=1}^N \frac{\lambda_{r,l}^2 \sigma_{r,l}^2}{\delta_{r,l}^2}\right)^{\sum_{l=1}^N i_l}} \times \prod_{n=1}^N \frac{\Gamma(i_n + |m_-|)}{\Gamma(i_n + m_>) i_n!} \left(\frac{\sigma_{r,n} \lambda_{r,n}}{\delta_{r,n}}\right)^{2i_n} \quad (3a)$$

$$b_0 = 2Nm_< - 1, \quad (3b)$$

onde $m_+ \triangleq m_1 + m_2$, $m_- \triangleq m_1 - m_2$, $m_< \triangleq \min(m_1, m_2)$, $m_> \triangleq \max(m_1, m_2)$, $r \triangleq \arg \max_{v \in \{1,2\}} m_v$, o índice $v \in \{1, 2\}$ identifica os enlaces transmissor-RIS e RIS-receptor, e

$$\Phi = \frac{\frac{2^{N(1-2m_<)}}{\Gamma(m_>)\Gamma(m_<)^N} \left(\prod_{n=1}^N \frac{1}{\delta_{1,n}^2 \delta_{2,n}^2}\right)^{m_<}}{\left(1 + \sum_{l=1}^N \frac{\lambda_{1,l}^2 \sigma_{1,l}^2}{2\delta_{1,l}^2}\right)^{m_1} \left(1 + \sum_{l=1}^N \frac{\lambda_{2,l}^2 \sigma_{2,l}^2}{2\delta_{2,l}^2}\right)^{m_2}}. \quad (4)$$

Os parâmetros m_v controlam a severidade do desvanecimento Nakagami- m ; $\lambda_{v,n}$ controlam a dependência estatística entre os componentes correlacionados do canal; $\sigma_{v,n}^2$ representam a variância dos componentes Gaussianos subjacentes, com $\mathbb{E}[H_{v,n}^2] = m_v \sigma_{v,n}^2$; e

$$\delta_{v,n}^2 = \sigma_{v,n}^2 \frac{1 - \lambda_{v,n}^2}{2}. \quad (5)$$

A expressão em (3a) contém N séries aninhadas e depende fortemente da correlação; termos de ordem superior tornam-se relevantes à medida que a correlação aumenta [3]. Assim, o custo não está apenas em avaliar uma fórmula fechada, mas em truncar numericamente uma soma multidimensional com precisão suficiente. Essa limitação computacional é o aspecto que se pretende contornar por meio do aprendizado supervisionado quando milhares de configurações precisam ser avaliadas. Além disso, enquanto b_0 depende apenas de N e de $m_<$, a_0 agrega os efeitos dos parâmetros de correlação e das potências de todos os elementos, o que justifica concentrar o modelo de aprendizado na estimativa do coeficiente linear.

O problema de regressão será definido como

$$\mathbf{x} \mapsto y = \log_{10}(a_0), \quad (6)$$

onde $\mathbf{x}$ reúne os parâmetros físicos empregados na geração de cada configuração. O valor estimado será recuperado por $\hat{a}_0 = 10^{\hat{y}}$. Quando N variar, a estrutura de correlação deverá ser codificada por uma parametrização de dimensão fixa compatível com o XGBoost.

III. HIPÓTESE

A hipótese central deste trabalho é que um modelo de regressão baseado em XGBoost, treinado com dados gerados a partir da formulação analítica de referência, seja capaz de estimar com elevada precisão o coeficiente assintótico linear para diferentes configurações dos parâmetros do sistema RIS, reduzindo o custo computacional associado ao cálculo analítico repetitivo. Especificamente, assume-se que a transformação $y = \log_{10}(a_0)$ viabiliza o mapeamento não linear das características do canal, permitindo reproduzir fidedignamente o comportamento assintótico da PDF e da CDF com um custo computacional significativamente inferior ao cálculo analítico repetitivo. Adicionalmente, espera-se que a análise por SHAP permita identificar a contribuição relativa dos parâmetros do canal para as estimativas do modelo e revelar tendências compatíveis com o comportamento previsto pela formulação analítica, especialmente em relação ao efeito da correlação espacial e do número de elementos da RIS.

IV. METODOLOGIA

A metodologia será baseada na geração de um conjunto de dados sintético a partir da formulação analítica de referência apresentada em [3]. Cada amostra corresponderá a uma configuração do sistema RIS, definida pelo número de elementos da superfície, pelos parâmetros de desvanecimento Nakagami- m , pelos níveis de correlação espacial e pelas potências médias dos canais. Para cada combinação desses parâmetros, será calculado o correspondente coeficiente assintótico linear, que será utilizado como valor de referência para o treinamento do modelo.

Como o coeficiente assintótico pode variar por várias ordens de magnitude, o XGBoost será treinado para estimar o logaritmo decimal desse coeficiente, em vez de utilizar diretamente seu valor original. Essa transformação reduz a faixa dinâmica da variável de interesse e torna o processo de regressão numericamente mais estável. Após a predição, será

aplicada a transformação inversa para recuperar o coeficiente assintótico em sua escala original.

Após a geração do conjunto de dados, as amostras serão embaralhadas e separadas em três subconjuntos: 70% para treinamento, 15% para validação e 15% para teste. O conjunto de treinamento será utilizado para ajustar o modelo XGBoost, enquanto o conjunto de validação será empregado para selecionar uma configuração adequada do modelo e controlar o sobreajuste. O conjunto de teste permanecerá isolado durante essa etapa e será utilizado somente na avaliação final da capacidade preditiva.

O desempenho será avaliado comparando os valores estimados pelo XGBoost com os valores obtidos pela formulação analítica. Serão utilizadas métricas de erro no domínio logarítmico, como MAE e RMSE, além do coeficiente de determinação R^2 . Também será medido o tempo necessário para obter o coeficiente utilizando o modelo treinado e o cálculo analítico, permitindo avaliar o ganho computacional proporcionado pelo modelo substituto.

Após a avaliação preditiva, será utilizada a metodologia SHAP para interpretar o comportamento aprendido pelo XGBoost. A análise buscará identificar quais parâmetros do sistema apresentam maior influência sobre as estimativas e como diferentes valores desses parâmetros afetam a saída do modelo. Será dada atenção especial ao efeito da correlação espacial e à sua relação com o número de elementos da RIS. Os resultados de SHAP serão utilizados como ferramenta de interpretação do modelo e serão confrontados com o comportamento previsto pela formulação analítica.

Por fim, para verificar se as estimativas preservam o significado físico do problema, valores selecionados do coeficiente estimado serão utilizados na reconstrução do comportamento assintótico da distribuição da SNR. Esses resultados serão comparados com a formulação analítica de referência e com simulações de Monte Carlo, permitindo avaliar se a aproximação obtida pelo XGBoost é suficientemente precisa para representar o comportamento do sistema.

V. RESULTADOS ESPERADOS

Espera-se que o XGBoost reproduza $\log_{10}(a_0)$ com erro reduzido no domínio de treinamento e que a transformação inversa preserve a ordem de grandeza do coeficiente em diferentes configurações. O principal ganho esperado é a substituição de avaliações repetitivas da série multidimensional por inferências rápidas, tornando viáveis varreduras paramétricas mais extensas. A reconstrução da PDF/CDF deverá permanecer próxima das curvas analíticas e de Monte Carlo no regime assintótico. Do ponto de vista de interpretabilidade, espera-se que SHAP permita identificar a contribuição relativa de N , dos parâmetros Nakagami- m , das potências e, sobretudo, da correlação espacial, além de indicar regiões nas quais a interação entre N e correlação se torna mais relevante. O resultado final deverá constituir um modelo substituto preditivo e interpretável, adequado tanto à aceleração da análise assintótica quanto à exploração orientada por dados da sensibilidade de a_0 .

REFERENCES

- [1] E. Basar, M. Di Renzo, J. De Rosny, M. Debbah, M.-S. Alouini, and R. Zhang, "Wireless communications through reconfigurable intelligent surfaces," *IEEE Access*, vol. 7, pp. 116753–116773, 2019.
- [2] Q. Wu, S. Zhang, B. Zheng, C. You, and R. Zhang, "Intelligent reflecting surface-aided wireless communications: A tutorial," *IEEE Trans. Commun.*, vol. 69, no. 5, pp. 3313–3351, May 2021.
- [3] P. I. Tilleria Lucero, B. F. S. Rodríguez, F. D. A. García, and J. C. S. S. Filho, "Impact of fading correlation on the high-SNR regime of reconfigurable intelligent surfaces," in *Proc. XLIII Simpósio Brasileiro de Telecomunicações e Processamento de Sinais (SBrT)*, 2025, doi: 10.14209/sbrt.2025.1571151573.
- [4] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining*, 2016, pp. 785–794.
- [5] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 4765–4774.
- [6] L. Grinsztajn, E. Oyallon, and G. Varoquaux, "Why do tree-based models still outperform deep learning on typical tabular data?," in *Advances in Neural Information Processing Systems*, vol. 35, 2022.